

Co-clustering Interactions via Attentive Hypergraph Neural Network

Tianchi Yang

摘要

数据迅速增加，对于数据的整合聚类要求也越来越高，现已经提出许多聚类方法来发现交互关系，进而对下游任务提供先验知识。交互可以看作发生在多个对象之间的动作。因此，通常会将对象及其中的成对关系建模为图里的节点和边，利用图中的结构信息和属性信息聚类。然而，它们仅对真实整个交互中的部分信息进行建模和利用，即要么将整个交互分解为几个成对的子交互以进行简化，要么仅专注于对某些特定类型的对象进行聚类，这限制了性能和聚类的可解释性。

为了解决这个问题，作者通过 Attentive Hypergraph 神经网络 (CIAH) 对交互进行协同聚类。特别是，通过超图对交互进行更全面的建模，提出了一个注意力超图神经网络来编码整个交互，其中使用注意力机制来选择重要属性进行解释。然后，引入了一种显着性方法来引导注意力与属性的真实重要性更加一致，即基于显着性的一致性。此外，还提出了一种新的联合聚类方法，对交互的表示和属性选择的相应分布进行联合聚类，即基于聚类的一致性。广泛的实验表明，CIAH 在公共数据集和真实工业数据集上的表现都明显优于最先进的聚类方法^[1]。

关键词：无监督聚类；超图；神经网络

1 引言

互联网时代迅速发展，产生了海量数据，这其中包括了社交网络、引文网络、用户商品交互网络等复杂网络。这些网络都可以看做不同个体对象直接的交互动作所组成的集合，一般把对象及其关系建模为图的节点和边。

聚类是一种最基本的数据挖掘任务，交互数据上的聚类（即图上的聚类）可以揭示有价值的个体交互关系，进而为下游任务提供有用的先验知识。早期的研究通常使用图表示方法只编码结构信息然后对对象进行聚类。然后，为了考虑属性的增益，研究人员基于属性图来探索结合结构信息和属性信息的优势以获得更好的聚类效果^[1]。进一步的，考虑使用异质图来更准确的对交互进行建模与编码。

此外，虽然这种交互网络的聚类已经得到了许多深入的研究，但实际中的交互数据仍然复杂得难以处理，完整交互的每一个部分对于发现交互模式都很必要。例如推荐时考虑包括但不限于”什么人在什么情况下在哪个商店购买了什么商品”，白领为了高效工作经常在下点半咖啡。如果忽略这种时间上下文中的”下午”的条件，可能会出现片面结果，在午夜向其推荐咖啡。从完整交互中选择出重要属性也可对聚类结果作出更准确的解释，聚类结果的可释性可以帮助理解模型决策背后的原因^[1]。相反，基于交互的不完整的建模，则可能会遗漏一些有助于解释的关键信息，大多数方法试图选择重要且简洁的属性来作为聚类结果的解释。到目前为止，很少有人尝试探索整个交互中的丰富属性以进行聚类解释，现有的聚类方法仅对真实交互中的部分信息进行了建模和利用，即要么将整个交互分解为了若干个成对的子交互以进行简化，要么只专注于对某些特定类型的交互对象进行聚类，而不是针对完整交互。

作者将首次尝试对完整交互进行聚类，而不是对传统聚类方法中的简单交互。它还可以进一步通过从完整交互的任一部分中选择出关键的属性，以此作为聚类结果的解释。工作有如下三个主要难点：

1. 如何有效地对完整交互进行建模和编码？每个完整交互都涉及了不确定个数带有属性的交互对象和交互环境以及多个对象之间的交互关系。因此，使用前文提到的图方法是不足以对这种完整交互进行建模和编码的；

2. 如何从完整交互中选择出可解释的关键属性？使用注意力机制来选择属性是一种常见的解决方案。然而它在解释性能力上备受质疑，因为注意力权重有时会与属性的真正重要性不一致，尤其是在面对完整交互中的丰富属性时；

3. 如何同时提高对完整交互的聚类性能和可解释性？如先前工作中所研究的，在注意力机制中，聚类与属性选择的分布之间没有严格的相关性，这将导致损害聚类的性能。

针对上面三个问题，对于建模与编码问题，作者提出通过注意力超图神经网络对完整交互进行协同聚类。具体地，首先构建了一个超图，超边非常适用于表示完整交互。然后，提出了一个注意力超图神经网络来显式地学习完整交互（超边）的表示，其中采用注意力机制来选择出重要的属性以作为聚类结果的解释；

对于注意力权重和真实重要性之间的不一致问题，作者受显著性方法的启发，提出了基于显著性的一致性来使属性选择（即注意力权重）的分布与显著性方法给出的重要性保持一致；

对于类簇和属性选择分布之间的对应关系问题，受现有工作启发，提出了基于聚类的一致性：属于同一类簇内的完整交互应具有相似的属性选择分布，而不同类簇中的属性选择分布应不同。为此，论文提出了一种新颖的协同聚类方法，它对完整交互的表示和相应的属性选择分布进行协同聚类，从而提高聚类的性能和可解释性^[1]。

综上，该论文的主要贡献可归纳如下：

1. 这是对完整交互进行聚类的首次尝试，这可以从复杂的交互数据中发现更全面和可解释性更强的聚类模式；

2. 为完整交互提出了一种基于注意力超图神经网络的协同聚类方法，称为 CIAH。通过超图建模完整交互后，设计了一个注意力超图神经网络，以及一个具有基于显著性和基于聚类的一致性的新颖协同聚类方法。

3. 大量实验证明了该方法在完整交互的聚类上的有效性。此外，离线和在线的推荐实验也验证了其在下游应用中的实用价值。

2 相关工作

聚类属于一种非监督学习方法，它试图在无标签的数据集中发现其分布状况或模式，是从现有数据中挖掘潜在信息，将相似的样本归为同一类别，划分为多个簇的过程，是最基本的数据分析任务之一。聚类算法作为传统机器学习中常用的算法之一，得到了广泛的关注与研究。在过去的几十年中，已经开发了一大类聚类算法并成功应用于各种实际应用，例如图像聚类和文本聚类。经典聚类方法算法分为原型聚类、密度聚类、层次聚类等以及其他图聚类^[2]。图聚类是一种基于图划分理论的算法，它一般是将图中的节点聚为一个个簇，使簇间差异大，簇内相似，高内聚低耦合。与其他聚类算法相

比,图聚类算法有些明显的优势。该方法可识别任意形状的聚类,使其在现实生活中得到广泛的应用。目前,在许多领域都成功地运用了图聚类算法,比如文本挖掘,网页划分,图像分割,人际关系分析,语音识别等。

2.1 传统聚类方法

传统的聚类方法大致分为 5 类,分别是以 K-means 等为代表的划分聚类、以 DBSCAN 为代表的密度聚类、以 Chameleon 为代表的层次聚类、以谱聚类为代表的图聚类和以高斯混合聚类 (Gaussian mixture model, GMM)^[3]为代表的模型聚类。近年来,网格聚类方法、量子聚类方法、谱聚类方法、粒度聚类方法、概率图聚类方法、同步聚类方法等也流行起来。

基于划分的聚类算法通过构造一个迭代过程来优化目标函数,当优化到目标函数的最小值或极小值时,可以得到数据集的一些不相交的子集,通常认为此时得到的每个子集就是一个聚类。k-means^[4]算法和 FCM(FuzzyC Means) 算法^[5]是该类型中最著名的两个算法。层次聚类方法使用一个距离矩阵作为输入,经过聚类后得到一个反映该数据集分布状况的聚类层次结构图,层次聚类方法有 AGNES(AGglomerativeNESting)、BIRCH (Balanced Iterative Reducing and Clustering using Hierarchies)^[6]、CURE(Clustering Using REpresentative) 算法等。基于密度的聚类算法试图通过稀疏区域来划分高密度区域以发现明显的聚类和孤立点,主要用于空间型数据的聚类。DBSCAN(Density-Based Spatial Clustering of Applications with Noise) 算法^[7]就是一个最为著名的基于密度的聚类算法。基于模型的聚类算法借助于一些统计模型来获得数据集的聚类分布信息。

2.2 基于深度网络聚类方法

深度学习的突破导致了人工智能和机器学习的范式转变,在包括聚类在内的许多重要任务上取得了巨大成功。因此,深度聚类引起了极大的关注。深度聚类的基本思想是将聚类目标融入到深度学习强大的表示能力中。因此,学习有效的数据表示是深度聚类的关键先决条件。深度聚类的本质是用神经网络学习一个聚类导向的特征表示,并用神经网络拟合数据内蕴的聚类规律。例如,在 K-means 中使用自动编码器学习的表示^[8];利用聚类损失来帮助自动编码器学习具有高聚类凝聚力的数据表示;使用变分自动编码器来学习更好的聚类数据表示。深度聚类可以分为基于前馈神经网络的深度聚类模型 (RFADC),基于自动编码器深度聚类模型 (AutoEncoder, AE)、基于图卷积神经网络的深度聚类模型 (Deep Neural Network, DNN)、基于生成对抗网络 (Generative Adversarial Network, GAN)、基于变分自动编码器 (Variational Auto-Encoder, VAE)、基于生成模型的深度聚类模型 GNN 的深度聚类等。随着图神经网络在简单图结构上的逐渐成熟,研究者开始将 GNN 迁移到超图结构上,并提出了一系列超图神经网络方法^[9]。

2.3 基于超图聚类方法

图上的聚类方法而言,在早期研究中,方法通常执行网络嵌入方法来学习交互对象的表示,然后应用聚类方法。然后,最近的研究探索结合属性和结构的强度,设计属性图方法以获得更好的聚类性能,如统计方法、图神经网络等。最近,越来越多的研究人员进一步考虑不同类型的节点或链接,并通过异构图更好地模拟交互。然而,这些方法仍然只对整个交互中的部分信息进行建模和利用,从而限制了聚类性能^[1]。

聚类的解释也引起了广泛关注,以揭示模型决策。现有方法通常通过查找/选择交互中涉及的简

洁属性来提供聚类解释，这些属性可以分为两组。

一组被称为建模后可解释性，但有人质疑它不能提供对模型决策的直接洞察。另一组通常将决策树或规则学习模块集成到聚类方法中以选择关键属性并执行预建模可解释性。这些方法专用于某些特定的聚类方法，不能简单地推广到我们对整个交互的聚类。不同的是，我们选择在深度神经网络中广泛使用的注意机制来从整个交互中选择属性^[10]。

然而现存聚类方法无法全面利用完整交互过程中的信息，现实世界的关系往往是错综复杂彼此交叉影响的，是多个节点共同发挥作用关系，如论文的引文关系中多位作者共同创作一篇文章，亦或者电影与演员之间多对多关系，这些高阶关系形成一个整体，原本简单图结构很难适合这种关系，原来的图聚类算法也表现不佳。超图 (hypergraph) 扩展了图的定义, 其中的一条超边 (hyperedge) 可以包含任意数量的节点, 因此可以直接储存高阶关联，每条超边可以定义权重 w 。超图对于复杂关系有更加强大的表达能力，因此基于超图的聚类更符合真实网络环境。最近，一些研究人员将图表示方法进一步推广到超图，并开发了超图神经网络方法，以便可以利用更复杂和广泛的信息^[11]。然而，这些方法只关注某些特定类型的对象，无法学习整个交互的表示。此外，他们也不能选择重要的属性来提供解释，因为基于注意力的超图方法主要针对节点级别而不是特征级别。因此，它们不适合我们的任务。

3 本文方法

3.1 本文方法概述

为完整交互提出了一种新颖的基于注意力超图的协同聚类方法。如上图 1 所示，首先构建一个超图来对完整交互进行建模，其中每个完整交互都表示为连接所有相关对象的超边。然后设计了一个注意力超图神经网络来显式地学习完整交互（超边）的表示，同时通过注意力机制来选择相关的关键属性以作为聚类结果的解释。

此外，文章还提出了一种基于显著性的一致性，即通过显著性方法使属性选择的分布与属性的真实重要性保持一致，作者将引入积分梯度方法来指导注意力。

最后，提出了一种新颖的协同聚类方法，对完整交互和相应的属性选择分布进行协同聚类，以实现基于聚类的一致性^[1]。如图 1 所示：

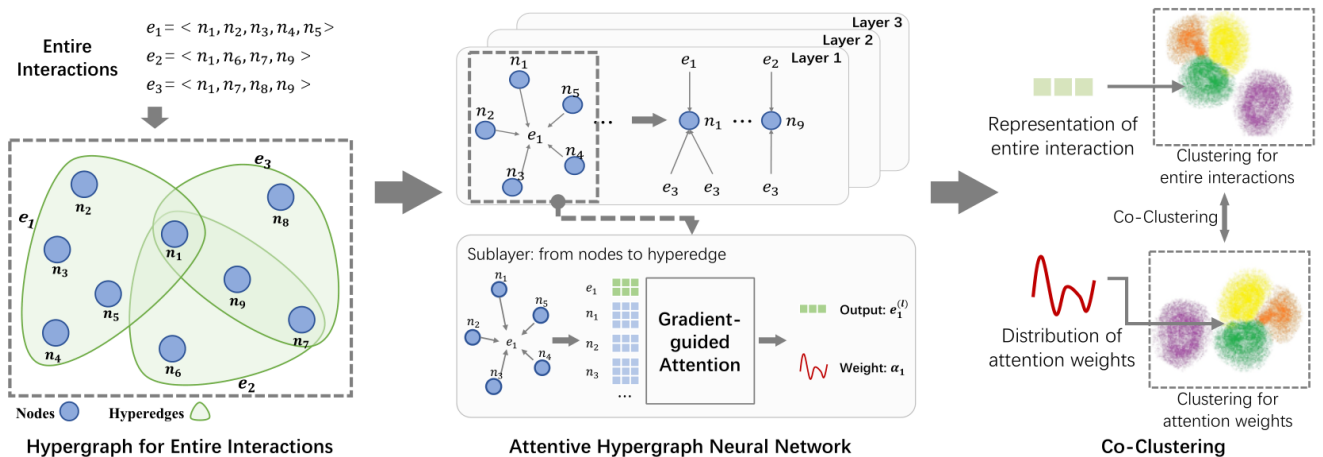


图 1: CIAH 示意图

3.2 建模完整交互超图

我们将完整交互建模为了超图，其中每条超边代表了一个完整交互，它连接了该交互所涉及的所有类型的对象节点。具体来说，对于涉及了 5 个对象 n_1, n_2, \dots, n_5 的完整交互 e_1 ，我们将构建一条超边将这些对象连接起来。此外，将这些对象的属性 $a_j (j=1, \dots, 5)$ 附加到节点特征上，并将交互环境 $A_{e_1}^i$ 例如时空上下文（应该被视为交互的属性而不是对象的属性）附加到超边特征上。因此，这样的一条超边及其连接节点及其特征合在一起，就可以表示一个完整交互的实例。

对整个交互进行聚类。给定一组完整的交互 $\varepsilon = \{e_1, \dots, e_{|\varepsilon|}\}$ 和集群数量 C ，对整个交互进行聚类的目标是将 ε 划分为 C 不相交的子集，使得同一集群内的整个交互具有相似的属性选择分布 $P(A_{e_s}) \approx P(A_{e_t})$ ，而不同聚类中的那些是不相似的，其中 $\mathcal{A}_e = \mathcal{A}_e^o \cup \mathcal{A}_e^i$ 是表示属性选择分布的分类分布。

3.3 注意力超图神经网络

为了促使注意力机制可以选择属性，将超边和节点的表示初始化为特征矩阵而不是向量。形式地， $e_i^{(0)} \in R^{f_i \times d}$ 和 $n_j^{(0)} \in R^{f_j \times d}$ 分别表示超边 e_i 和节点 n_j 的初始 d 维表示，其中特征矩阵的每一行表示节点/超边的某个特定属性。

给定一个超图与其关联矩阵 $H \in R^{|\mathcal{N}| \times \varepsilon}$ ，令 D_e 、 D_n 和 W 分别表示边的度对角矩阵，节点度对角矩阵和超边的预定义权重（默认 1）^[12]。将信息聚合过程参数化为两阶段的基于注意力的聚合规则为：

$$e_i^{(l+1)} = att(e_i^{(l)}, \{n_j^{(l)} | n_j \in e_i\}) \quad (1)$$

$$n_j^{(l+1)} = att(n_j^{(l)}, \{e_i^{(l+1)} | n_j \in e_i\}) \quad (2)$$

如公式 (1)，超边 e_i 的新表示 $e_i^{(l+1)}$ 由自身及其所连接的节点 $\{n_j^{(l)} | n_j \in e_i\}$ 聚合而得到。为了在聚类完整交互过程中识别并选择出重要的属性，将这条超边及其连接的节点的特征矩阵按行拼接成一个组合特征矩阵 $X_i^{(l)}$ ，如公式 (3) 所示。然后应用一个特征感知的软注意力机制，具体形式化过程如下：

$$X_i^{(l)} = concat(e_i^{(l)}, \{n_j^{(l)} | n_j \in e_i\}) \quad (3)$$

$$\alpha_j^{(l+1)} = softmax(X_i^{(l)T} \cdot a^{(l)}) \quad (4)$$

$$att(e_i^{(l)}, \{n_j^{(l)} | n_j \in e_i\}) = \alpha_j^{(l)T} \cdot X_i^{(l)} \quad (5)$$

公式 (4) 得到完整交互 e_i 的属性选择分布 $\alpha_i^{(l)}$ ，再由公式 (1) 和公式 (5) 得到超边的新表示 $e_i^{(l+1)}$ 。简单起见，仅使用第一层中的注意力权重 $\alpha_i = \alpha_i^{(1)}$ 作为完整交互 e_i 的属性选择分布。

注意力权重和真实属性重要性存在不一致性^[13]，属性选择的分布可能也是存在质疑的。受计算机视觉领域中显著性解释的启发，引入积分梯度来指导注意力机制的学习^[14]。

$$IG(\alpha_{ik}) = \left\| x^k \odot \int_0^1 \frac{\partial F(t \cdot x^k)}{\partial x^k} dt \right\| \quad (6)$$

$$\mathcal{L}_{grad} = \sum_{e_i \in \varepsilon} KL(SoftMax(IG(\alpha_i), \alpha_i) \quad (7)$$

IG 表示基向量为 0 时的积分梯度。 x^k 表示组合特征矩阵 X_i^l 的第 k 行。 \odot 表示哈达玛积。对于 α_i 的每个元素 α_{ik} 而言（表示第 k 个属性在第 i 个完整交互中的权重），可由公式 (6) 得到对应积分梯度。使用 $SoftMax$ 函数将梯度转换为分布，然后应用 KL 散度让它指导注意力权重的分布。

3.4 协同聚类完整交互

由于聚类得到的类簇有时与对应的属性选择分布并不一致，文章提出了一种新的协同聚类方法对完整交互及其相应的注意力权重进行协同聚类，从而确保基于聚类的一致性。具体方法如下：通过上面部分已经得到了完整交互的表示与对应的注意力属性选择分布。具体地，给定第 i 个交互的表示 e_i 和第 u 个可训练的聚类质心 u_u (聚类质心初始化随机生成)，按照现有的神经聚类方法，可以以学生 t 分布为核来测量它们之间的相似性，如公式 (8)，其中 v 是 t 分布的自由度，文章中令 $v=1$ ， q_{iu} 可以看做是将交互分配给类簇的概率^[15]：

$$q_{iu} = \frac{(1 + \|e_i - \mu_u\|^2 / v)^{-\frac{v+1}{2}}}{\sum_s (1 + \|e_i - \mu_s\|^2 / v)^{-\frac{v+1}{2}}} \quad (8)$$

目标函数设定为公式 (9)：

$$p_{iu} = \frac{q_{iu}^2 / \sum_t q_{tu}}{\sum_s q_{is}^2 / \sum_t q_{ts}} \quad (9)$$

通过最小化 Q_{emb} 和 P_{emb} 之间的 KL 散度，目标分布 P_{emb} 可以帮助模型实现高内聚和低耦合的聚类要求，从而实现聚类过程。

然而，目标是要确保每个类簇一一对应于属性选择分布，即基于聚类的一致性。因此，对于每个完整交互的属性选择分布 α ，也可以通过类似的可训练的聚类质心 v ，为注意力权重计算分配分布 $Q_{wgt} = [q'_{iu}]$ 和目标分布 $P_{wgt} = [p'_{iu}]$ 。具体地，给定第个完整交互的对应属性选择分布，可以有公式 (10) 和公式 (11)^[15]：

$$q'_{iu} = \frac{(1 + \|\alpha_i - \nu_u\|^2 / v)^{-\frac{v+1}{2}}}{\sum_s (1 + \|\alpha_i - \nu_s\|^2 / v)^{-\frac{v+1}{2}}} \quad (10)$$

$$p'_{iu} = \frac{q_{iu}'^2 / \sum_t q'_{tu}}{\sum_s q_{is}'^2 / \sum_t q_{ts}'} \quad (11)$$

为了这两组分布可以相互指导直到收敛，文章开创性地提出了一种协同聚类方法，即交换它们的目标分布，相互指导来实现聚类目的。形式化地，最小化损失函数公式 (12)^[1]：

$$\mathcal{L}_{clu} = KL(P_{emb} || Q_{wgt}) + KL(P_{wgt} || Q_{emb}) \quad (12)$$

4 复现细节

4.1 与已有开源代码对比

代码基本源于作者改论文源码^[1]，解决部分 bug 跑通代码，并做了部分改动。

Procedure 1 Co-clustering Interactions via Attentive Hyper-graph Neural Network.

Input: hyper-edges e , node n , iterations N

Output: hyper-edges clustering results C

for l **in** iterations N **do**

 拼接后分别按照公式 (1) 与公式 (2) 计算新的超边表示和新的节点表示, 同时得到注意力权重分布;
 计算聚类中心, 按公式 (8)-(11) 计算概率与目标函数, 计算损失;
 由公式 (6)、(7) 积分梯度指导注意力学习, 计算损失;
 反向传播更新参数;

end

4.2 实验环境搭建

TensorFlow-GPU==1.14.0

culatoolkit==10.2.89

culdnn=7.6.5

dgl-cuda11.1=0.9.1

python=3.7.1

pytorch=1.13.0

4.3 创新点

在注意力超图网络中增加了一层处理网络, 进一步提取聚合信息, 效果略微提升; 在聚类完整交互部分对完整交互信息聚类质心和注意力属性聚类质心采用 k-means 来初始化, 效果改变不明显。

5 实验结果分析

5.1 数据集

Dataset		# Nodes	# HE	# Attr.	# Cate.
ACM	Paper	4,025	4,025	1,902	3
	Author	7,167			
	Field	60			
IMDB	Movie	4,661	4,661	1,256	3
	Actor	5,841			
	Director	2,270			
MT-4	User	37,748	40,000	5789	4
	POI	17,994			
	Item	123,629			
MT-9	User	79,967	90,000	5945	9
	POI	25,834			
	Item	245,064			

图 2: 实验数据说明

ACM 数据集 2 包含 4,025 篇论文以及另外两种类型的节点: 作者和领域, 如图 (2)。构建一个超图, 其中每个超边连接一篇论文及其所有相应的作者和领域, 从而代表对一篇论文的整个交互。因此, 可以根据包含论文的分类来标记超边。每篇论文的属性是摘要的词袋表示, 而其他节点和超边的属性是单热表示, 因为它们的特征不是由数据集提供的。

IMDB 数据集包含 4,661 部电影以及另外两种类型的节点：演员和导演, 如图 (2)。与 ACM 类似, 构建了一个超图, 其中每个超边代表了与演员和导演连接的电影的完整交互。根据其包含电影的类别来标记超边。每部电影的属性是其情节的词袋表示, 而其他节点和超边的属性是单热表示。

5.2 评价指标体系

采用两种评价指标进行验证, 分别为 NMI 和 ARI。

评价指标 NMI 计算如公式 (13)-(15):

$$MI(X, Y) = \sum_{i=1}^{|X|} \sum_{j=1}^{|Y|} P(i, j) \log \left(\frac{P(i, j)}{P(i)P'(j)} \right) \quad (13)$$

$$H(X) = - \sum_{i=1}^{|X|} P(i) \log(P(i)); H(Y) = - \sum_{j=1}^{|Y|} P'(j) \log(P'(j)) \quad (14)$$

$$NMI(X, Y) = \frac{2MI(X, Y)}{H(X) + H(Y)} \quad (15)$$

评价指标 ARI 计算如 (16)

$$ARI = \frac{\sum_{ij} \binom{n_{ij}}{2} - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} \right] / \binom{n}{2}}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} \right] / \binom{n}{2}} \quad (16)$$

5.3 基线方法

对比其他基线方法, 借助 BUPT GAMMA Lab 的 HGNN 库^[16]中算法实现:

仅考虑属性的方法: K-means^[4]: 它是一种基于原始多热点特征的经典聚类方法。

仅考虑图结构的方法: HAN^[17]和 GTN^[18], 只考虑图的结构信息, 不考虑节点属性进行聚类。

同时考虑图结构和属性的方法: HGT^[19]: 它是一种 SOTA 异构图嵌入模型, 将节点和边的类型合并到传播步骤中。

同时考虑超图结构和属性的方法: HGNN^[20]: 它是一个超图谱卷积网络框架。我们将其卷积分成 2 阶段以进行显式超边表示。

5.4 实验结果及分析

表 1: 实验结果

Method	Hyper-	Graph	Attr.	IMDB		ACM	
				NMI	ARI	NMI	ARI
K-means	×	×	√	0.78	1.17	36.5	28.25
HAN	×	√	×	3.36	2.61	35.36	26.97
GTN	×	√	×	5.14	5.27	38.03	36.41
HGT	×	√	√	5.48	5.09	44.68	41.06
HGNN	√	√	√	2.03	1.25	26.31	25.42
CIAH	√	√	√	10.80	11.16	54.82	45.14
CIAH-2	√	√	√	12.02	11.25	55.20	45.83

实验结果如表 (1) 所示, 可以看到综合情况下只考虑属性信息的 K-means 效果最差; 在只考虑结构信息时评价稍高, 同时 GTN 方法一般要优于 HAN 方法; 同时考虑结构信息与属性信息的 HGT 基线方法相较前面只考虑单一方面的基线方法有较明显的提高; 同时考虑超图结构和属性的方法 HGNN 可能没有充分有效利用超图信息, 评价分数差于普通图。最后本文方法在各方面处于领先, 同时两层

处理提取网络的效果更得到些许提高。

6 总结与展望

首次尝试对整个交互进行聚类,这可以从真实的交互数据中提取更全面和可解释的聚类模式。特别是提出了一种通过注意力超图神经网络(CIAH)对整个交互进行联合聚类的方法。通过对整个交互进行超图建模,它设计了一个细心的超图神经网络,然后是一个新的联合聚类过程,具有基于显着性和基于聚类的一致性,以进一步改进。

大量实验验证了 CIAH 在公共数据集数据集上的有效性。在未来的工作中,将探索一种比简单堆叠层更易于解释的特征级交互解决方案,并在下游任务中更好地使用。

复现任务本人原创性工作不足,缺少创新性想法且没有独立实现代码,还应该加强这方面学习锻炼,早日做出实质性内容成果。

参考文献

- [1] YANG T, YANG C, ZHANG L, et al. Co-clustering Interactions via Attentive Hypergraph Neural Network[C]//Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '22). Association for Computing Machinery, 2022. DOI: 10.1145/3477495.3531868.
- [2] 陈新泉,周灵晶,刘耀中.聚类算法研究综述[J].集成技术,2017,6(3):41-49.
- [3] REYNOLDS D A, et al. Gaussian mixture models.[J]. Encyclopedia of biometrics, 2009, 741(659-663).
- [4] 王千,王成,冯振元,等. K-means 聚类算法研究综述[J]. 电子设计工程, 2012, 20(7): 21-24.
- [5] NAYAK J, NAIK B, BEHERA H. Fuzzy C-means (FCM) clustering algorithm: a decade review from 2000 to 2014[C]//Computational Intelligence in Data Mining-Volume 2: Proceedings of the International Conference on CIDM, 20-21 December 2014. 2015: 133-149.
- [6] PENG K, ZHENG L, XU X, et al. Balanced iterative reducing and clustering using hierarchies with principal component analysis (PBIRCH) for intrusion detection over big data in mobile cloud environment[C]//Security, Privacy, and Anonymity in Computation, Communication, and Storage: 11th International Conference and Satellite Workshops, SpaCCS 2018, Melbourne, NSW, Australia, December 11-13, 2018, Proceedings 11. 2018: 166-177.
- [7] BÄCKLUND H, HEDBLÖM A, NEIJMAN N. A density-based spatial clustering of application with noise[J]. Data Mining TNM033, 2011, 33: 11-30.
- [8] 何锦蓉. 深度子空间聚类算法研究[D]. 中国矿业大学, 2020.
- [9] 邓祥, 俞璐. 深度聚类算法综述[J]. 通信技术, 2021, 54(8): 1807-1814.
- [10] [1 孙, [1 刘, [1 赵. 聚类算法研究[J]. 软件学报, 2008, 19(1): 48-61.
- [11] PURKAIT P, CHIN T J, SADRI A, et al. Clustering with hypergraphs: the case for large hyperedges[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(9): 1697-1711.

- [12] BAI S, ZHANG F, TORR P H. Hypergraph convolution and hypergraph attention[J]. Pattern Recognition, 2021, 110: 107637.
- [13] JAIN S, WALLACE B C. Attention is not explanation[J]. arXiv preprint arXiv:1902.10186, 2019.
- [14] SUNDARARAJAN M, TALY A, YAN Q. Axiomatic attribution for deep networks[C] // International conference on machine learning. 2017: 3319-3328.
- [15] XIE J, GIRSHICK R, FARHADI A. Unsupervised deep embedding for clustering analysis[C] // International conference on machine learning. 2016: 478-487.
- [16] HAN H, ZHAO T, YANG C, et al. OpenHGNN: An Open Source Toolkit for Heterogeneous Graph Neural Network[C/OL] // CIKM '22: Proceedings of the 31st ACM International Conference on Information & Knowledge Management. Atlanta, GA, USA: Association for Computing Machinery, 2022: 3993-3997. <https://doi.org/10.1145/3511808.3557664>. DOI: 10.1145/3511808.3557664.
- [17] WANG X, JI H, SHI C, et al. Heterogeneous graph attention network[C] // The world wide web conference. 2019: 2022-2032.
- [18] YUN S, JEONG M, KIM R, et al. Graph transformer networks[J]. Advances in neural information processing systems, 2019, 32.
- [19] HU Z, DONG Y, WANG K, et al. Heterogeneous graph transformer[C] // Proceedings of the web conference 2020. 2020: 2704-2710.
- [20] FENG Y, YOU H, ZHANG Z, et al. Hypergraph neural networks[C] // Proceedings of the AAAI conference on artificial intelligence: vol. 33: 01. 2019: 3558-3565.